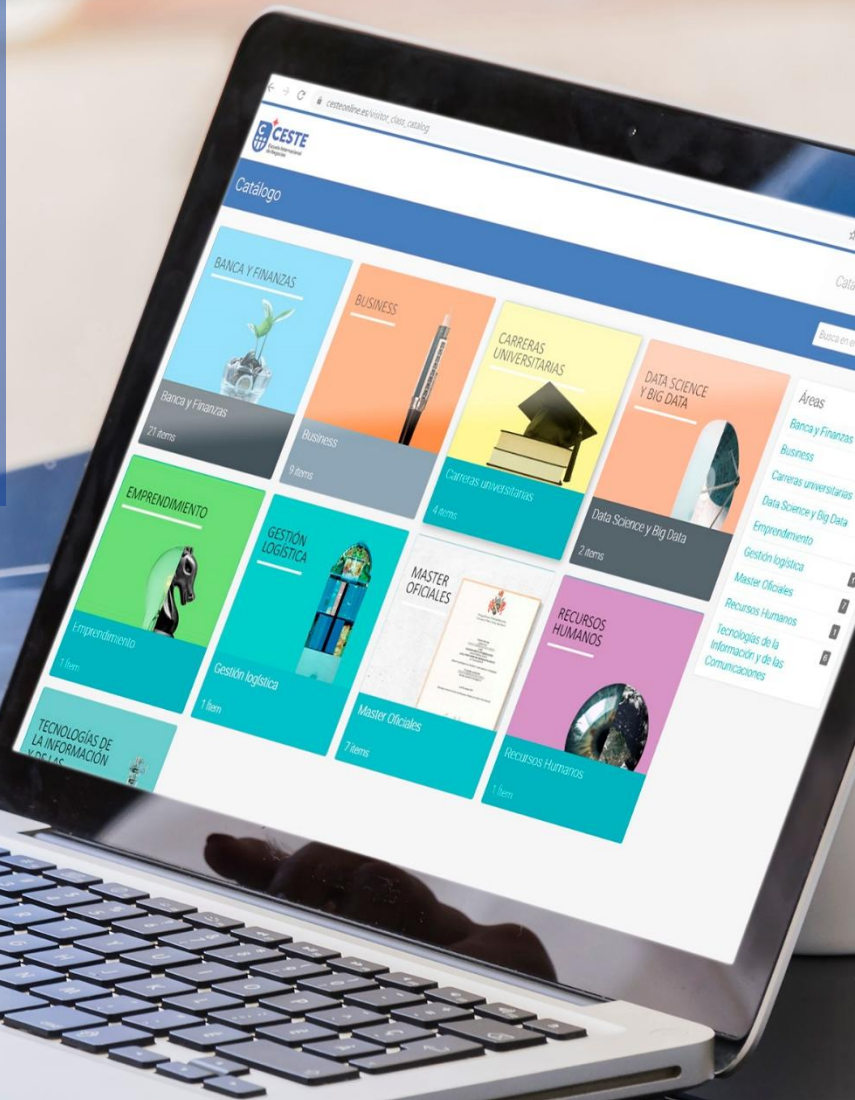


CESTE

Escuela Internacional de Negocios

Zaragoza (España)



¿Quién soy?



- Pablo Sanz Caperote
- Doble Grado en Ingeniería Informática – Matemáticas
- Profesional con más de 4 años de experiencia entorno al mundo de los datos.
- Casi 2 años trabajando con Databricks
- Varias certificaciones en Clouds (AWS, Azure, GCP)



www.linkedin.com/in/pablosanzcaperote

Introducción a Apache Spark: RDDs, DataFrames, Datasets y Spark SQL

Introducción a Apache Spark: RDDs, DataFrames, Datasets y Spark SQL

Índice | Fundamentos y diagnóstico de rendimiento

Cambiar

1. ¿Qué es spark?
2. Estructura de datos
3. Funciones en pyspark

Objetivos | Una primera toma de contacto con Spark y PySpark



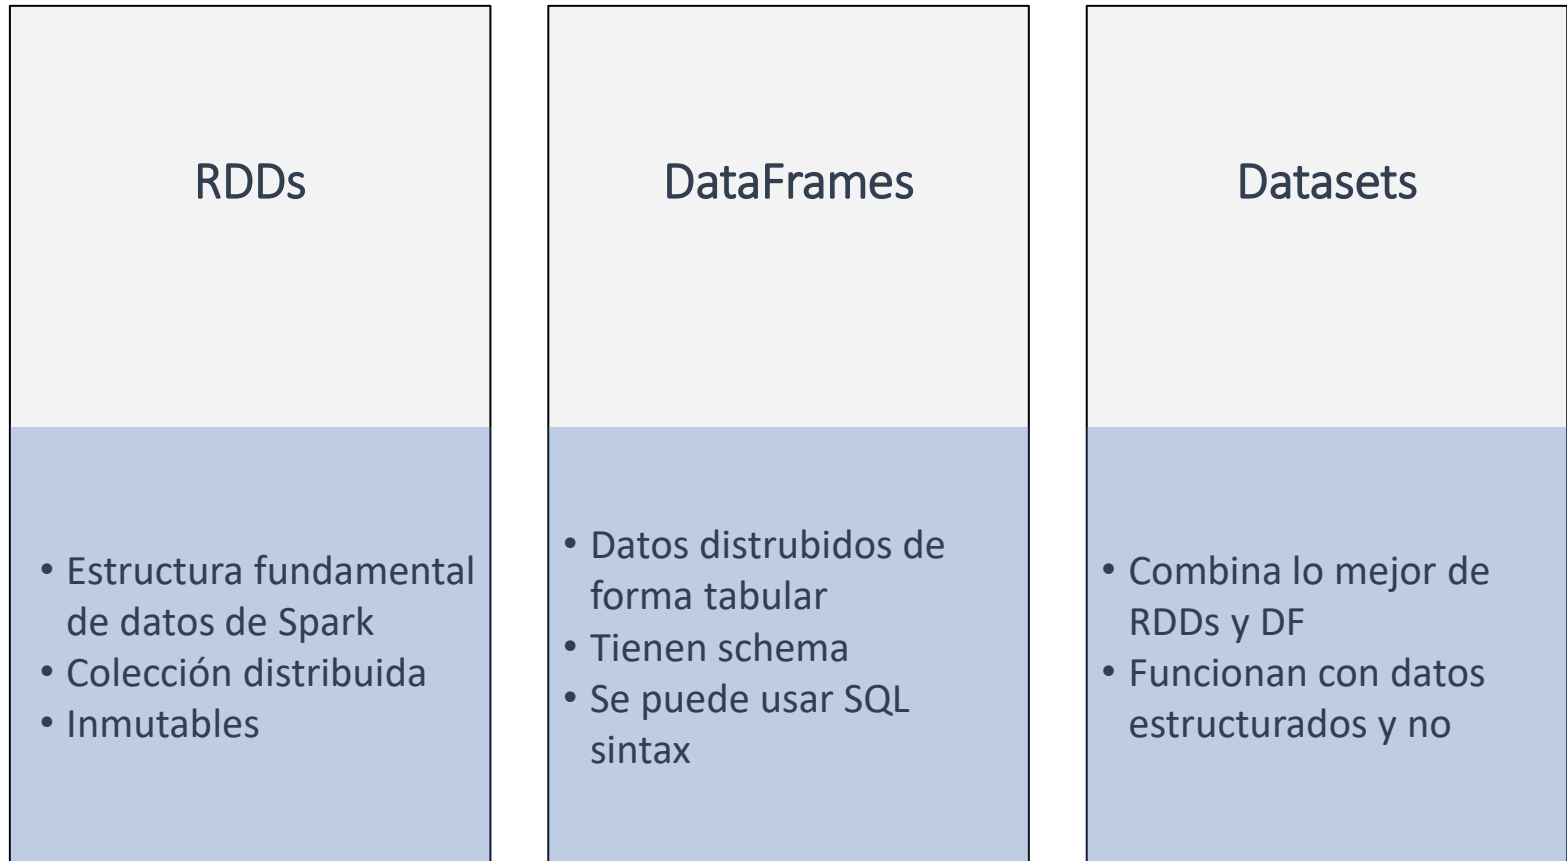
1. Entender Spark y sus principales componentes
2. Uso de Notebooks en Databricks
3. Uso de dbutils
4. Ejercicios sobre Spark

¿Qué es Apache Spark? | La mejor forma de tratar un volumen grande de datos




1. Motor unificado de analítica para procesar datos a gran escala
2. Motor de procesamiento distribuido
3. Permite desarrollo en Java, Scala, Python y R.
4. PySpark es la interfaz en Python de Apache Spark

Estructura de datos en Spark | Evolución en busca de mejoras



¿Cómo operar con los datos? | Transformaciones y acciones

Transformaciones



- Definen como se modifican los datos (evaluación perezosa):
 - `Select()`
 - `Filter()`
 - `withColumnn()`
 - `groupBy()`
 - `Join()`

Acciones



- Ejecutan el procesamiento y devuelven resultados:
 - `Show()`
 - `Count()`
 - `Collect()`
 - `Write()`

DEMO
A PRACTICAR CON PYSPARK



www.ceste.es